



FACULTAD DE CIENCIAS INTELIGENCIA ARTIFICIAL

Redes Bayesianas

Equipo: Skynet Scribes

Número de practica: 06

Sarah Sophía Olivares García
318360638

Marco Silva Huerta
316205326

Carlos Daniel Cortés Jiménez
420004846

Laura Itzel Tinoco Miguel
316020189

Luis Enrique García Gómez
315063880

Fernando Mendoza Eslava
319097690

Profesora: Cecilia Reyes Peña

Ayudante teoría: Karem Ramos Calpulalpan

Ayudante laboratorio: Tania Michelle Rubí Rojas

Semestre 2024-2

Fecha de entrega:
12 de Abril del 2024

Índice

1. Investigación	1
1.1. Fundamentos de redes bayesianas	1
1.2. Probabilidad condicional e independencia condicional	2
1.3. Representación Matematica	2
2. Desarrollo	5
2.1. Diseño 1	5
2.2. Diseño 2	5
2.3. Diseño 3	6
3. Análisis e interpretación de resultados	7
3.1. Diseño 1	7
3.2. Diseño 2	7
3.3. Diseño 3	8

1. Investigación

1.1. Fundamentos de redes bayesianas

Redes bayesianas

Las redes bayesianas nos permiten modelar un sistema mediante un conjunto de variables y sus respectivas relaciones de dependencia, permitiendo llevarlo a inferencia bayesiana con la que podemos estimar la probabilidad de relacionarse con variables no conocidas, con base a las conocidas. Las redes bayesianas generalmente también incluirán un conjunto de tablas de probabilidad, indicando las probabilidades para los valores verdadero o falso de las variables. El punto principal de las Redes Bayesianas es permitir que se realice una inferencia probabilística. Esto significa que la probabilidad de cada valor de un nodo en la red bayesiana se puede calcular cuando se conocen los valores de las otras variables.

Una red Bayesiana consta de:

- **Cualitativa** que describe las relaciones entre las distintas variables
- **Cuantitativa** que describe la fuerza de dichas relaciones mediante probabilidades condicionadas

Estos modelos tienen amplios usos en la clasificación, predicción, diagnostico, que brindan información sobre como se relaciones las variables llevándolos a un enfoque de causa y efecto, donde los vértices de la gráfica representan variables llamados nodos. Los nodos se representan como círculos que contienen el nombre de la variable. Las conexiones entre los nodos se nombran aristas.

Las redes Bayesianas se utilizan en una amplia gama de aplicaciones. Por ejemplo:

- En medicina, Las redes Bayesianas pueden ayudar a los médicos a evaluar la probabilidad de que un paciente tenga cierta enfermedad en función de los síntomas observados y los factores de riesgo.
- En finanzas, pueden utilizarse para evaluar riesgos y rendimientos en carteras de inversión.
- En reconocimiento de patrones, pueden utilizarse para clasificar imágenes o datos sensoriales.

- Predicción del tiempo: Pueden utilizarse para modelar la probabilidad de diferentes condiciones climáticas en función de variables como la temperatura, la presión atmosférica y la humedad.

En cada una de estas aplicaciones, las redes Bayesianas permiten modelar la incertidumbre y realizar inferencias probabilísticas sobre las variables de interés.

1.2. Probabilidad condicional e independencia condicional

1. Probabilidad Condicional:

La probabilidad condicional se refiere a la probabilidad de que ocurra un evento dado que otro evento ya ha ocurrido. Se denota como $P(A|B)$, que es la probabilidad de que el evento A ocurra dado que el evento B ha ocurrido. La fórmula para calcular la probabilidad condicional es:

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

Lo que significa que la probabilidad de A dado B es igual a la probabilidad de que ocurran ambos A y B dividida por la probabilidad de que ocurra B .

Un ejemplo es: supongamos que tenemos dos eventos A y B , donde A representa sacar una carta roja de una baraja estándar de 52 cartas, y B representa sacar una carta de corazones. La probabilidad de sacar una carta roja dado que hemos sacado una carta de corazones se puede calcular utilizando la fórmula de probabilidad condicional:

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

Donde $P(A \cap B)$ es la probabilidad de sacar una carta roja que también sea un corazón, y $P(B)$ es la probabilidad de sacar una carta de corazones. Si la carta roja que hemos sacado también es un corazón, entonces la probabilidad de A dado B sería $1/13$, ya que hay 13 cartas de corazones en total en una baraja de 52 cartas.

2. Independencia Condicional:

Es la situación en la que dos eventos son independientes dado un tercer evento. Formalmente, dos eventos A y B son independientes condicionalmente a un evento C si la probabilidad de A dado B no cambia incluso si sabemos que C ha ocurrido. Se denota como $A \perp\!\!\!\perp B | C$.

Por ejemplo, consideremos tres eventos A , B y C , donde A representa sacar una carta roja de una baraja de cartas, B representa sacar una carta de corazones y C representa sacar una carta alta (as, rey, reina o jota). Si los eventos A y B son independientes condicionalmente a C , esto significa que la probabilidad de sacar una carta roja que también sea un corazón no cambia incluso si sabemos que hemos sacado una carta alta. En este caso, si A y B son independientes condicionalmente a C , entonces la probabilidad de A dado B sigue siendo $1/13$, incluso después de que hemos sacado una carta alta.

1.3. Representación Matemática

Una red Bayesiana se define como un par (G, Θ) , donde G es un grafo dirigido acíclico (DAG) y Θ es un conjunto de tablas de probabilidad condicional (TPC).

El grafo G consiste en un conjunto de nodos V y un conjunto de arcos E . Cada nodo representa una variable aleatoria y cada arco representa una dependencia probabilística entre las variables. Las tablas de probabilidad

condicional Θ especifican la probabilidad de cada valor posible de cada variable condicionado a los valores de sus nodos padres.

Para representar la probabilidad conjunta de todas las variables en la red, utilizamos la regla del producto:

$$P(\text{variables}) = \prod_{i=1}^n P(X_i | \text{padres}(X_i))$$

donde X_i es la variable i -ésima en la red y $\text{padres}(X_i)$ son los nodos padres de X_i en el grafo.

Por ejemplo, supongamos que tenemos dos variables A y B en una red Bayesiana, donde B depende de A . Podemos representar esto como:

$$P(A, B) = P(A) \cdot P(B | A)$$

Aquí, $P(A)$ es la probabilidad marginal de A y $P(B | A)$ es la probabilidad condicional de B dado A . La probabilidad conjunta de A y B se calcula multiplicando la probabilidad de A por la probabilidad condicional de B dado A .

Modelo con nodos y aristas

Ejemplo de una red Bayesiana y los significados de los nodos y aristas:

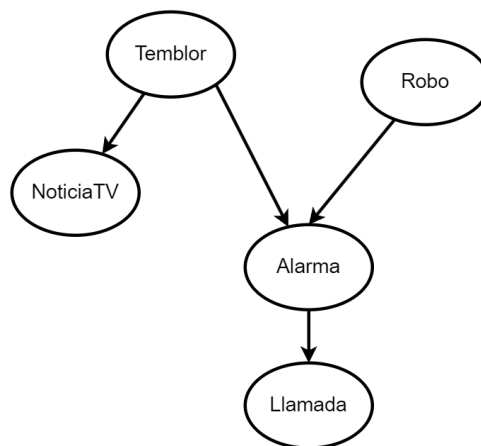


Figura 1: Diagrama de una red Bayesiana

Observemos estos elementos en la red Bayesiana:

- Si hay un robo es más probable suene la alarma, lo que hace más probable que que reciba una llamada.
- Si recibo una llamada se incrementa la probabilidad de que haya sonado la alarma y por tanto de que me hayan robado
- Si oigo en la radio que ha habido un terremoto es más probable que éste haya ocurrido, lo que hace más probable que que suene la alarma.
- Si suena la alarma se incrementa la probabilidad de que haya ocurrido un terremoto y por tanto de que oiga la noticia en la television.
- Si suena la alarma y ocurre una de las causas (terremoto) , me creo menos que haya ocurrido el otro evento causante (robo)

- Y viceversa, Si suena la alarma y ocurre una de las causas (robo) me creo menos que haya ocurrido el otro evento causante (terremoto)

Notemos como los nodos y aristas en la red Bayesiana representan las relaciones probabilísticas entre las variables y cómo se propagan las probabilidades a través de la red. Siendo una herramienta poderosa para modelar sistemas complejos y realizar inferencias probabilísticas. Dependiendo de nuestro enfoque de estudio, podemos utilizar las redes bayesianas para modelar sistemas complejos y realizar inferencias probabilísticas.

Elementos de una red Bayesiana:

- Nodos: Cada nodo en el grafo representa una variable aleatoria. Que representan aspectos del sistema que estamos modelando.
- Aristas: Las aristas representan las relaciones entre las variables. Una arista que va desde el nodo A al nodo B indica que el nodo B es dependiente del nodo A. Esto puede interpretarse como ".^{el} nodo A causa o influye en el nodo B".

Distribuciones de probabilidad condicional

- Para cada nodo en la red, este tiene asociada una distribución de probabilidad condicional que describe la probabilidad de los posibles valores del nodo dado los valores de sus nodos padres.
- Las Distribuciones de probabilidad condicional reflejan las relaciones causales entre las variables representadas por los nodos. Por ejemplo, en una red que modela el clima y la probabilidad de lluvia, la Distribuciones de probabilidad condicional del nodo "lluvia" podría depender de los nodos "humedad" y "neblina".

Ventajas y limitaciones de las redes bayesianas

Las ventajas de las Redes Bayesianas son las siguientes:

1. Las Redes Bayesianas representan visualmente todas las relaciones entre las variables en el sistema con arcos de conexión.
2. Es fácil reconocer la dependencia e independencia entre varios nodos.
3. Las redes bayesianas pueden manejar situaciones en las que el conjunto de datos está incompleto ya que el modelo da cuenta de las dependencias entre todas las variables.
4. Las redes bayesianas pueden mapear escenarios donde no es factible/práctico medir todas las variables debido a las limitaciones del sistema (costos, falta de suficientes sensores, etc.)
5. Ayuda a modelar sistemas ruidosos.
6. Se puede utilizar para cualquier modelo de sistema, desde todos los parámetros conocidos hasta ningún parámetro conocido.

Las limitaciones de las Redes Bayesianas son las siguientes:

1. Todas diferentes caminos o ramificaciones que pueden tomar los nodos en el grafo, deben ser calculadas para calcular la probabilidad de cualquier rama.
2. La calidad de los resultados de la red depende de la calidad de las creencias o modelos previos. Una variable es solo una parte de una red bayesiana si crees que el sistema depende de ella.
3. El cálculo de la red es NP-duro, por lo que es muy difícil y posiblemente costoso.
4. Los cálculos y probabilidades utilizando la regla y marginación de Bayes pueden volverse complejos.

2. Desarrollo

Implementación de redes bayesianas con pgmpy

2.1. Diseño 1

La descripción completa de como se diseño el modelo de redes bayesianas que indaga en la satisfacción laboral usando horas de trabajo, balance trabajo-vida y satisfacción laboral esta en el archivo:

`src/Redesbayesianas.ipynb`

2.2. Diseño 2

En la sección de *análisis e interpretación de resultados* se nos pide hacer un ajuste interesante de las probabilidades, esta es la descripción de dicho cambio.

Recordemos el modelo original, donde las redes bayesianas son las encargadas de indagar en la satisfacción laboral y cuenta con tres variables clave:

- (a) Horas de trabajo (H): *largas, moderadas o cortas*.
- (b) Balance trabajo-vida (B): *equilibrado o no equilibrado*.
- (c) Satisfacción laboral (S): *satisfecho, neutral e insatisfecho*.

Cuando pensé en la modificación para esta parte del trabajo pensé en un cambio que he tenido a lo largo de la carrera ya que cuando entre, pensaba que ir a la oficina a programar sería algo que me hiciera muy feliz, paso el tiempo y ahora sé que el cambio que me gustaría es trabajar desde casas.

Trabajar desde casa no es solo para programadores o trabajos que requieran estar detras de una computadora, pensé en pesonas del campo, más específicamente en un pastor quien tiene que ver que sus ovejas no sa vayan muy lejos y si esta se va, poder encontrarla rapidamente. Es así como pensé en un segundo parametro para esta tarea: ayuda de inteligencia artificial (IA).

Imaginemos que el pasor esta en una zona montañosa, aunque si debe estar con sus ovejas la ayuda de la inteligencia artificial podría ayudar con un dron que siga a sus ovejas y si una sale del limite, el dron la pueda seguir y decirle al pastor donde esta.

Basicamente las dos modificaciones que se tendrán contempladas serán las de un horario más flexible (trabajando desde casa) y el poder contar con herramientas con inteligencia artificial que ayuden a terminar nuestras tareas dentro del trabajo.

Horas de trabajo

La flexibilidad en horarios de trabajo permitido hacerlo desde casa con ayuda de la IA nos da una distribución más equilibrada de las horas de trabajo ya que se pueden cumplir en ciertos lapsos a lo largo del día o poder terminar mucho antes y no estar un una oficina.

- Valores antes: $[[0.6], [0.3], [0.1]]$ *largas, moderadas o cortas*
- Valores ahora: $[[0.08], [0.65], [0.27]]$ *largas, moderadas o cortas*

Balance trabajo-vida

Arriba mencionamos que un horario en casa y el contar con herramientas que le permitan hacer su trabajo más rapido podría hacer que el trabajador termine antes sus actividades lo que le permitira aprovechar el tiempo para hacer otras actividades en su vida.

- Valores antes: $[[0.4, 0.7, 0.2], [0.6, 0.3, 0.8]]$ *equilibrado o no equilibrado*.
- Valores ahora: $[[0.5, 0.85, 0.88], [0.5, 0.15, 0.12]]$ *equilibrado o no equilibrado*.

Satisfacción laboral

- Valores antes: $[[0.8, 0.05], [0.15, 0.6], [0.05, 0.35]]$ *satisfecho, neutral e insatisfecho*.
- Valores ahora: $[[0.88, 0.55], [0.1, 0.35], [0.02, 0.1]]$ *satisfecho, neutral e insatisfecho*.

Para un trabajador entonces poder terminar sus activades antes y poder estar en casa para ser más productivo en su vida (por supuesto que es el caso optimo) encontrando balance trabajo-vida podría llevar a una mayor satisfacción laboral en general.

El código es exactamente igual que en el diseño 1, lo que cambia son los valores descritos arriba. El archivo que contiene ese código es: `src/redModificada.ipynb`

2.3. Diseño 3

Para esta sección se nos pide plantear una mejora o extensión posible de la red bayesiana creada. Justificando la mejora para el análisis y la personalización de las situaciones laborales.

Para hacer este modelo partiremos del diseño 1, eso quiere decir que adecuaciones realizadas en tiempo y ayuda de herramientas no son consideradas. Entonces para esta mejora tenemos diversos factores a considerar como lo pueden ser los horarios en casa, tendencia del trabajo en el mundo, horas de sueño, calidad de salud, entre otras. Para este tercer modelo usaremos una condición que nos parece engloba de manera general a casi todos los trabajos y es que a muchos nos a tocado estar trabajando y tener un jefe o lider que al que le tenemos que hacer la chamba, o no sabe dirigir al equipo o incluso sabemos mucho más que él o ella.

Entonces la variable es: Impacto del Liderazgo. Este nodo nos dice como el empleado percibe y afecta su trabajo diario el liderazgo de sus jefes con los siguientes valores:

- Positivo
- Neutral
- Negativo

La implementación en código nuevamente tambien se basa en el diseño 1, la ruta del archivo es: `src/redExtension.ipynb`

3. Análisis e interpretación de resultados

3.1. Diseño 1

Después de definir la estructura de la red bayesiana y las tablas de probabilidad condicional (CPTs) correspondientes, el código verifica la validez del modelo y luego realiza una inferencia específica, la cual es la probabilidad de estar satisfecho con el trabajo bajo las siguientes condiciones:

- Horas de trabajo: moderadas
- Balance trabajo-vida: equilibrado

Los resultados obtenidos son los siguientes:

```

1 La probabilidad de estar satisfecho es:
2 +-----+-----+
3 | Satisfaccion laboral | phi(Satisfaccion laboral) |
4 +-----+-----+
5 | Satisfaccion laboral(satisfecho) | 0.8000 |
6 +-----+-----+
7 | Satisfaccion laboral(neutral) | 0.1500 |
8 +-----+-----+
9 | Satisfaccion laboral(insatisfecho) | 0.0500 |
10 +-----+-----+

```

Estos resultados ilustran la dinámica entre el volumen de trabajo y el equilibrio entre la vida personal y laboral de la siguiente manera:

- **Influencia directa de las horas de trabajo en la satisfacción laboral:** Las horas de trabajo moderadas pueden conducir a una mayor satisfacción laboral (0.8000 de probabilidad de estar satisfecho), mientras que un exceso de horas de trabajo podría disminuir la satisfacción laboral.
- **Importancia del balance trabajo-vida en la satisfacción laboral:** El balance trabajo-vida equilibrado también tiene un impacto significativo en la satisfacción laboral. Bajo condiciones de balance trabajo-vida equilibrado, incluso si las horas de trabajo son moderadas, la satisfacción laboral sigue siendo alta (0.8000 de probabilidad de estar satisfecho), esto resalta la importancia de no solo considerar las horas de trabajo, sino también cómo se equilibran con la vida personal para mantener una satisfacción laboral óptima.
- **Influencia indirecta de las horas de trabajo a través del balance trabajo-vida:** El balance trabajo-vida actúa como un mediador entre las horas de trabajo y la Satisfacción laboral, aunque las horas de trabajo pueden tener un impacto directo en la satisfacción laboral, este impacto puede ser mitigado o amplificado por el equilibrio entre la vida personal y laboral.

En resumen, este modelo resalta la importancia de mantener un balance saludable entre el trabajo y la vida personal para promover una mayor satisfacción laboral, muestra cómo las horas de trabajo y el equilibrio trabajo-vida interactúan entre sí para influir en la percepción de satisfacción en el trabajo, y enfatiza la necesidad de gestionar adecuadamente estas variables para mantener un entorno laboral saludable y productivo.

3.2. Diseño 2

Actualizar los paquetes para no tener problemas

- `pip install --upgrade jupyter ipywidgets`
- `pip install --upgrade pgmpy`

Comparación

Estos son los resultados de la primera red

```
El modelo es válido.
La probabilidad de estar satisfecho es:
+-----+-----+
| Satisfacción laboral          | phi(Satisfacción laboral) |
+=====+=====+
| Satisfacción laboral(satisfecho) | 0.8000 |
+-----+-----+
| Satisfacción laboral(neutral)   | 0.1500 |
+-----+-----+
| Satisfacción laboral(insatisfecho) | 0.0500 |
+-----+-----+
```

Estos son los resultados de la red modificada incluyendo las variaciones de las horas de trabajo flexibles y la ayuda de IA dentro de las actividades del trabajo.

```
El modelo es válido.
La probabilidad de estar satisfecho con las modificaciones:
+-----+-----+
| Satisfacción laboral          | phi(Satisfacción laboral) |
+=====+=====+
| Satisfacción laboral(satisfecho) | 0.8800 |
+-----+-----+
| Satisfacción laboral(neutral)   | 0.1000 |
+-----+-----+
| Satisfacción laboral(insatisfecho) | 0.0200 |
+-----+-----+
```

Observamos como se ha incrementado 88 % la la satisfacción lo que nos dice que las condiciones nuevas para el trabajo tienen un impacto positivo en la vida de los empleados. Para la respuestas neutrales respecto a su satisfacción en el trabajo es baja 10 % lo que podemos decir que pocas personas se sentirán en las mismas situaciones con los dos cambios realizados, mientras que con un 2 % la probabilidad de insatisfacción es muy baja lo cual dice que las personas les gusta más poder tener un horario flexible desde casa y tener ayuda de la tecnología.

3.3. Diseño 3

Estos son los resultados de la primera red

```
El modelo es válido.
La probabilidad de estar satisfecho es:
+-----+-----+
| Satisfacción laboral          | phi(Satisfacción laboral) |
+=====+=====+
| Satisfacción laboral(satisfecho) | 0.8000 |
+-----+-----+
| Satisfacción laboral(neutral)   | 0.1500 |
+-----+-----+
| Satisfacción laboral(insatisfecho) | 0.0500 |
+-----+-----+
```

Estos son los resultados de la red extendida, agregando el nodo de impacto del lider.

+-----+-----+	
Satisfacción laboral	phi(Satisfacción laboral)
+=====+	
Satisfacción laboral(satisfecho)	0.7000
+-----+	
Satisfacción laboral(neutral)	0.1000
+-----+	
Satisfacción laboral(insatisfecho)	0.2000
+-----+	

Vemos como ahora baja el porcentaje de estar satisfecho a un 70 % con nuestra variable del jefe. Así como tambien bajo la parte neutral de un 15 % a un 10 %. Finalmente vemos como ahora es un 20 % la probabilidad de estar insatisfecho por el impacto que sienten los empleados cuadno no se tiene un jefe de calidad.

Referencias

- [RN16] Stuart Russell y Peter Norvig. *Inteligencia Artificial Un Enfoque moderno*. 2nd. Pearson Prentice Hall, 2016.